

Trabalho da matéria Fundamentos em ciência de dados feito por:

Nome : Adryann Henrique Oliveira Olivatti

Número Usp = 17363240

```
import matplotlib.pyplot as plt
import pandas as pd
import numpy as np
import seaborn as sns
from IPython.display import HTML, display
```

```
#importando a tabela do github da Cibeles para fazer o tratamento dos dados
url = "https://raw.githubusercontent.com/cibelerusso/Datasets/main/DadosDecisoes.csv"
dados = pd.read_csv(url)

# a) Inicialmente, classifique os funcionários em dois grupos (Produtividade bin: "Alta"ou "Baixa"):
# • Alta produtividade: funcionários com produtividade acima da mediana;
# • Baixa produtividade: funcionários com produtividade abaixo ou igual á mediana

mediana_produtividade = dados['Produtividade'].median() #calculando a mediana dos dados

dados['Produtividade_bin'] = np.where(
    dados['Produtividade'] > mediana_produtividade, 'Alta', 'Baixa'
) #criando a coluna com os dados binarizados em produtividade 'Baixa e Alta'
print(f"A mediana da produtividade é {mediana_produtividade}")
```

A mediana da produtividade é 87.04

```
#tabela de funcionarios com alta produtividade (alta produtividade significa funcionarios que tem a produt
funcionario_alta_produtividade = dados[dados['Produtividade_bin'] == 'Alta'] # filtra os dados
```

```
funcionario_alta_produtividade.head(230) #expoem os dados
```

	ID	Idade	Gênero	Departamento	Salário	Horas_Trabalhadas	Produtividade	Satisfação	Tempo_Empresa
1	2	39	Feminino	Vendas	2536.32	48	107.84	98.62	4
2	3	39	Masculino	Marketing	7377.81	44	95.66	80.23	11
3	4	27	Feminino	Vendas	2536.32	40	88.89	94.63	8
6	7	44	Feminino	TI	22417.62	48	108.49	77.47	15
7	8	37	Feminino	RH	6396.44	40	89.92	100.00	8
...	...	...	...	...	...	...	...	...	...
218	219	29	Masculino	TI	12341.16	45	103.15	89.23	0
219	220	20	Masculino	Vendas	2536.32	48	103.86	82.21	0
220	221	20	Masculino	TI	13983.42	46	93.72	100.00	2
223	224	23	Feminino	RH	6691.17	45	100.64	84.49	5
224	225	44	Masculino	TI	26868.83	41	87.30	68.63	19

114 rows × 12 columns

Next steps:

[Generate code with funcionario_alta_produtividade](#)

[New interactive sheet](#)

Aqui observa-se que trabalhadores home-office possuem uma produtividade maior, isso fica bem evidente

```
#Tabela de funcionarios com baixa produtividade(baixa produtividade significa que sao funcionarios que ten
funcionario_baixa_produtividade = dados[dados['Produtividade_bin'] == 'Baixa'] #Filtra os dados
funcionario_baixa_produtividade.head(230) #expoem os dados
```

ID	Idade	Gênero	Departamento	Salário	Horas_Trabalhadas	Produtividade	Satisfação	Tempo_Empresa
----	-------	--------	--------------	---------	-------------------	---------------	------------	---------------

0	1	34	Masculino	RH	3848.89	36	84.89	94.33	0
4	5	41	Feminino	Vendas	2536.32	37	80.97	86.44	11
5	6	39	Feminino	Vendas	2536.32	36	81.80	73.90	2
9	10	31	Masculino	Vendas	2536.32	33	77.26	100.00	0
10	11	27	Masculino	Marketing	11944.30	37	84.69	76.07	8
...	...	...	...	...	...	...	...	...	...
225	226	36	Feminino	RH	3711.26	34	81.89	76.52	9
226	227	21	Feminino	Marketing	2536.32	34	85.63	100.00	0
227	228	43	Feminino	Vendas	5717.90	38	86.55	82.46	12
228	229	48	Feminino	Marketing	15638.38	38	85.72	68.05	14
229	230	54	Feminino	Marketing	9422.09	32	73.03	82.86	5

116 rows × 12 columns

Next steps:

[Generate code with funcionario_baixa_produtividade](#)[New interactive sheet](#)

Trabalhadores que tem uma produtividade menor adota em maior parte o modelo presencial e também possuem uma quantidade de horas semanais trabalhadas menor

Realize uma análise exploratória de dados. Para isso:

(b) Identifique o tipo (quantitativa discreta, quantitativa contínua ou qualitativa nominal ou ordinal) de cada variável do conjunto de dados.

1. Variáveis Qualitativas Nominais

São categorias que servem apenas para classificar ou identificar, sem nenhuma relação de ordem ou hierarquia.

São categorias que servem apenas para classificar os funcionários, sem nenhuma relação de ordem ou hierarquia.

ID

Motivo: É apenas um código numérico para diferenciar um funcionário do outro. Esses números não indicam quantidade e não faz sentido somá-los ou tirar a média deles.

Gênero

Motivo: Divide os dados em grupos (ex: Masculino, Feminino). São apenas rótulos textuais e nenhum grupo é "maior" ou "melhor" que o outro.

Departamento

Motivo: Classifica o funcionário pelo seu setor de trabalho (ex: TI, RH, Vendas). São categorias puramente qualitativas e sem hierarquia.

Home_Office

Motivo: É uma variável categórica binária (geralmente respondida com "Sim" ou "Não"). Apenas indica a modalidade de trabalho, sem valor numérico real.

2. Variáveis Qualitativas Ordinais

São categorias (rótulos ou conceitos), mas que possuem uma ordem ou escala natural de intensidade.

Satisfação

Motivo: Mede um sentimento ou percepção em graus (ex: Insatisfeito, Neutro, Satisfeito). Embora às vezes receba notas de 1 a 5, os números servem apenas para representar uma ordem clara de preferência ou contentamento.

3. Variáveis Quantitativas Discretas

São valores numéricos que representam uma contagem, ou seja, assumem apenas valores inteiros e isolados (não existem valores "quebrados").

Idade

Motivo: Embora o tempo corra continuamente, a idade em bancos de dados de empresas é registrada como uma contagem de

anos completos vividos (25 anos, 36 anos, etc.).

Cursos_Realizados

Motivo: Resulta de uma contagem direta de eventos. O funcionário faz 1, 2 ou 3 cursos; é impossível ele ter feito "2,4 cursos".

4. Variáveis Quantitativas Contínuas

São valores numéricos que resultam de uma medição e podem assumir qualquer valor decimal (números "quebrados") dentro de um intervalo.

Salário

Motivo: É um valor monetário medido. O dinheiro pode ser infinitamente fracionado em centavos (ex: R\$ 4.500,50), o que o torna uma variável contínua.

Horas_Trabalhadas

Motivo: É uma grandeza de tempo. O tempo é contínuo por natureza, pois um funcionário pode trabalhar frações de horas (ex: 40 horas e 30 minutos equivalem a 40,5 horas).

Tempo_Empresa

Motivo: Assim como as horas trabalhadas, mede a duração da jornada do funcionário na empresa (pode ser medido em meses ou anos parciais, como 2,5 anos de casa).

Produtividade

Motivo: Geralmente é calculada através de uma taxa, índice ou porcentagem (ex: 87,5% das metas batidas). Como o resultado dessa divisão gera números decimais contínuos, ela se enquadra aqui.

```
#(c) Para variáveis qualitativas, utilize tabelas de frequência, gráficos de barras ou gráficos de setores
# --- PREPARAÇÃO EXTRA DOS SEUS DADOS ---
# 1. Ajustando a Satisfação de números para categorias (Baixa, Média, Alta)
dados["Satisfação_Cat"] = pd.cut(
    dados["Satisfação"],
    bins=[0, 75, 90, 101],
```

```
        labels=["Baixa", "Média", "Alta"],
    )

# Lista com as variáveis que você quer analisar
variaveis = ["ID", "Gênero", "Departamento", "Home_Office", "Satisfação_Cat"]

# --- LAÇO PARA GERAR TABELA E GRÁFICO LADO A LADO ---
for var in variaveis:
    # Ajuste para o ID não quebrar o visual (mostra apenas os 10 primeiros)
    if var == "ID":
        dados_var = dados["ID"].head(10)
        titulo_sufixo = " (Primeiros 10)"
    else:
        dados_var = dados[var]
        titulo_sufixo = ""

    # 1. Calcular Frequência Absoluta e Relativa
    freq_abs = dados_var.value_counts()
    freq_rel = (dados_var.value_counts(normalize=True) * 100).round(1)

    tabela_frequencia = pd.DataFrame(
        {"Frequência Absoluta": freq_abs, "Frequência Relativa (%)": freq_rel}
    )

    # 2. Criar a estrutura com 2 colunas lado a lado
    fig, axes = plt.subplots(1, 2, figsize=(15, 4))

    # --- LADO ESQUERDO: Desenha a Tabela ---
    axes[0].axis("off") # Limpa o fundo de gráfico
    tabela_visual = axes[0].table(
        cellText=tabela_frequencia.values,
        rowLabels=tabela_frequencia.index,
        colLabels=tabela_frequencia.columns,
        loc="center",
        cellLoc="center",
    )
    tabela_visual.scale(1, 1.8) # Ajusta o tamanho das linhas
```

```

tabela_visual.set_size(1, 1.0) # Ajusta o tamanho das células
axes[0].set_title(
    f"Tabela de Frequência: {var.replace('_Cat', '')}{titulo_sufixo}",
    fontsize=13,
    fontweight="bold",
    pad=10,
)

# --- LADO DIREITO: Desenha o Gráfico de Barras ---
dados_var.value_counts().plot(kind="bar", ax=axes[1], color="#5da4e2")
axes[1].set_title(
    f"Gráfico de Barras: {var.replace('_Cat', '')}{titulo_sufixo}",
    fontsize=13,
    fontweight="bold",
)
axes[1].set_xlabel("Categorias")
axes[1].set_ylabel("Quantidade")
axes[1].tick_params(
    axis="x", rotation=0 if var != "Departamento" else 30
) # Inclina se for o setor

# Ajusta os espaços e plota o par (Tabela + Gráfico)
plt.tight_layout()
plt.show()
print("\n" + "-" * 100 + "\n")

```

Tabela de Frequência: ID (Primeiros 10)		
	Frequência Absoluta	Frequência Relativa (%)
1	1.0	10.0
2	1.0	10.0
3	1.0	10.0
4	1.0	10.0
5	1.0	10.0
6	1.0	10.0
7	1.0	10.0
8	1.0	10.0
9	1.0	10.0
10	1.0	10.0






Tabela de Frequência: Gênero

	Frequência Absoluta	Frequência Relativa (%)
Masculino	128.0	55.7
Feminino	102.0	44.3

Gráfico de Barras: Gênero**Tabela de Frequência: Departamento**

	Frequência Absoluta	Frequência Relativa (%)
TI	74.0	32.2
Vendas	62.0	27.0
Marketing	49.0	21.3
RH	45.0	19.6

Gráfico de Barras: Departamento**Tabela de Frequência: Home_Office**

	Frequência Absoluta	Frequência Relativa (%)
Não	115.0	50.0
Sim	115.0	50.0





Tabela de Frequência: Satisfação

	Frequência Absoluta	Frequência Relativa (%)
Alta	101.0	43.9
Média	90.0	39.1
Baixa	39.0	17.0



```
# (d) Para variáveis quantitativas, utilize medidas descritivas e visualizações adequadas (como his-
# togramas, boxplots, gráficos de dispersão ou gráficos de violino);
# Configuração visual básica
sns.set_theme(style="whitegrid")

# Lista com as suas variáveis quantitativas
variaveis_quant = [
    "Idade",
    "Cursos_Realizados",
    "Salário",
    "Horas_Trabalhadas",
    "Tempo_Empresa",
    "Produtividade",
]

# --- LAÇO PARA GERAR MEDIDAS E OS 3 GRÁFICOS LADO A LADO ---
for var in variaveis_quant:
    print(f"===== ANÁLISE DA VARIÁVEL: {var} =====")

    # 1. Calcular as Medidas Descritivas
    medidas = dados[var].describe()
    mediana_valor = dados[var].median()

    # Criando a tabela limpa
    tabela_medidas = pd.DataFrame(
        {
            "Média": [round(medidas["mean"], 2)],
            "Mediana": [round(mediana_valor, 2)],
            "Desvio Padrão": [round(medidas["std"], 2)],
            "Mínimo": [round(medidas["min"], 2)],
```

```
        "Máximo": [round(medidas["max"], 2)],
    },
    index=["Valores"],
)

# Exibe a tabela de texto no console
display(tabela_medidas)

# 2. Configurar a tela para colocar TRÊS gráficos lado a lado
fig, axes = plt.subplots(1, 3, figsize=(22, 5))

# --- GRAFICO 1 (Esquerda): Histograma ---
sns.histplot(data=dados, x=var, kde=True, ax=axes[0], color="#5da4e2")
axes[0].set_title(f"Histograma de {var}", fontsize=12, fontweight="bold")
axes[0].set_xlabel(var)
axes[0].set_ylabel("Frequência")

# --- GRAFICO 2 (Meio): Boxplot ---
sns.boxplot(data=dados, x=var, ax=axes[1], color="#99ff99")
axes[1].set_title(f"Boxplot de {var}", fontsize=12, fontweight="bold")
axes[1].set_xlabel(var)




# --- GRAFICO 3 (Direita): Gráfico de Dispersão ---
# Se a variável for a própria Produtividade, cruzamos com o Salário para não ficar uma linha reta
var_concorrente = "Salário" if var == "Produtividade" else "Produtividade"

sns.scatterplot(
    data=dados, x=var, y=var_concorrente, ax=axes[2], color="#ec7063"
)
axes[2].set_title(
    f"Dispersão: {var} vs {var_concorrente}",
    fontsize=12,
    fontweight="bold",
)
axes[2].set_xlabel(var)
axes[2].set_ylabel(var_concorrente)
```

```
# Mostra o conjunto de gráficos na tela
plt.tight_layout()
plt.show()
print("\n" + "-" * 110 + "\n")
```




===== ANÁLISE DA VARIÁVEL: Idade =====


	Média	Mediana	Desvio Padrão	Mínimo	Máximo	
Valores	30.55	29.0	8.22	18.0	54.0	
						



===== ANÁLISE DA VARIÁVEL: Cursos_Realizados =====


	Média	Mediana	Desvio Padrão	Mínimo	Máximo	
Valores	5.2	5.0	4.22	0.0	20.0	
						






===== ANÁLISE DA VARIÁVEL: Salário =====

	Média	Mediana	Desvio Padrão	Mínimo	Máximo	
Valores	8029.97	5667.56	6556.33	2536.32	29052.82	



===== ANÁLISE DA VARIÁVEL: Horas_Trabalhadas =====

	Média	Mediana	Desvio Padrão	Mínimo	Máximo	
Valores	38.85	38.0	5.82	30.0	48.0	






===== ANÁLISE DA VARIÁVEL: Tempo_Empresa =====

Média Mediana Desvio Padrão Mínimo Máximo



Valores 6.77 6.0 5.96 0.0 30.0






===== ANÁLISE DA VARIÁVEL: Produtividade =====

Média Mediana Desvio Padrão Mínimo Máximo



Valores 87.85 87.04 12.24 65.74 112.06



```
# 1. Configuração visual do Seaborn
sns.set_theme(style="whitegrid")

# Separando as variáveis por tipo para fazer as análises corretas
lista_qualitativas = ["Gênero", "Departamento", "Home_Office"]
lista_quantitativas = [
    "Idade",
    "Salário",
    "Horas_Trabalhadas",
    "Tempo_Empresa",
    "Cursos_Realizados",
]

# =====
# PARTE 1: ASSOCIAÇÃO COM VARIÁVEIS QUALITATIVAS (Cruzamento de categorias)
# =====
print(
    "=== 1. ASSOCIAÇÕES ENTRE PRODUTIVIDADE BIN E VARIÁVEIS QUALITATIVAS ===\n"
```

```
)

for var in lista_qualitativas:
    print(f"--> Cruzamento: Produtividade_bin vs {var}")

    # Cria a tabela de contingência (cruzamento) em percentual para comparar melhor
    tabela_cruzada = pd.crosstab(
        dados[var], dados["Produtividade_bin"], normalize="index"
    )
    tabela_cruzada = (tabela_cruzada * 100).round(1)

    # Configura a exibição lado a lado (Tabela e Gráfico)
    fig, axes = plt.subplots(1, 2, figsize=(14, 4))

    # Desenha a tabela no lado esquerdo
    axes[0].axis("off")
    tabela_visual = axes[0].table(
        cellText=tabela_cruzada.values,
        rowLabels=tabela_cruzada.index,
        colLabels=tabela_cruzada.columns,
        loc="center",
        cellLoc="center",
    )
    tabela_visual.scale(1, 1.8)
    axes[0].set_title(
        f"Distribuição % de {var}", fontsize=12, fontweight="bold"
    )

    # Desenha o gráfico de barras agrupadas no lado direito
    sns.countplot(
        data=dados,
        x=var,
        hue="Produtividade_bin",
        ax=axes[1],
        palette="coolwarm",
    )
    axes[1].set_title(f"Gráfico: {var} por Produtividade")
```

```
axes[1].set_ylabel("Quantidade de Funcionários")
axes[1].set_xlabel(var)

plt.tight_layout()
plt.show()
print("\n" + "-" * 100 + "\n")

# =====
# PARTE 2: ASSOCIAÇÃO COM VARIÁVEIS QUANTITATIVAS (Comparação de médias/grupos)
# =====
print(
    "=== 2. ASSOCIAÇÕES ENTRE PRODUTIVIDADE BIN E VARIÁVEIS QUANTITATIVAS ===\n"
)

for var in lista_quantitativas:
    print(
        f"--> Análise: {var} por Grupo de Produtividade"
    )

    # Cria a tabela resumo comparando a Média e Mediana da variável para quem é Alta ou Baixa produtividade
    tabela_resumo = dados.groupby(
        "Produtividade_bin"
    )[var].agg(["mean", "median"]).round(2)
    tabela_resumo.columns = ["Média", "Mediana"]

    # Configura a exibição lado a lado (Tabela e Boxplot)
    fig, axes = plt.subplots(1, 2, figsize=(14, 4))

    # Desenha a tabela resumo no lado esquerdo
    axes[0].axis("off")
    tabela_visual = axes[0].table(
        cellText=tabela_resumo.values,
        rowLabels=tabela_resumo.index,
        colLabels=tabela_resumo.columns,
        loc="center",
        cellloc="center"
```

```

        cellloc= center ,
    )
    tabela_visual.scale(1, 1.8)
    axes[0].set_title(f"Resumo de {var}", fontsize=12, fontweight="bold")

    # Desenha o Boxplot comparativo no lado direito (perfeito para ver diferença de comportamento)
    sns.boxplot(
        data=dados,
        x="Produtividade_bin",
        y=var,
        ax=axes[1],
        palette="coolwarm",
        hue="Produtividade_bin",
        legend=False,
    )
    axes[1].set_title(f"Boxplot de {var} por Produtividade")
    axes[1].set_xlabel("Grupo de Produtividade")
    axes[1].set_ylabel(var)

    plt.tight_layout()
    plt.show()
    print("\n" + "-" * 100 + "\n")


```

=== 1. ASSOCIAÇÕES ENTRE PRODUTIVIDADE BIN E VARIÁVEIS QUALITATIVAS ===

--> Cruzamento: Produtividade_bin vs Gênero

Distribuição % de Gênero


	Alta	Baixa
Feminino	50.0	50.0
Masculino	49.2	50.8



--> Cruzamento: Produtividade_bin vs Departamento

Distribuição % de Departamento


	Alta	Baixa
Marketing	53.1	46.9
RH	40.0	60.0
TI	51.4	48.6
Vendas	51.6	48.4



--> Cruzamento: Produtividade_bin vs Home_Office

Distribuição % de Home_Office

	Alta	Baixa
Não	0.0	100.0
Sim	99.1	0.9




=== 2. ASSOCIAÇÕES ENTRE PRODUTIVIDADE BIN E VARIÁVEIS QUANTITATIVAS ===

--> Análise: Idade por Grupo de Produtividade

Resumo de Idade


	Média	Mediana
Alta	30.82	30.0
Baixa	30.28	29.0



--> Análise: Salário por Grupo de Produtividade

Resumo de Salário


	Média	Mediana
Alta	9527.15	7125.84
Baixa	6558.61	3485.34



--> Análise: Horas_Trabalhadas por Grupo de Produtividade

Resumo de Horas_Trabalhadas


	Média	Mediana
Alta	43.79	44.0
Baixa	34.0	34.0



--> Análise: Tempo_Empresa por Grupo de Produtividade


Resumo de Tempo_Empresa

	Média	Mediana
Alta	6.83	6.0
Baixa	6.72	6.0




--> Análise: Cursos_Realizados por Grupo de Produtividade

Resumo de Cursos_Realizados



	Média	Mediana
Alta	5.51	5.0
Baixa	4.91	4.0



(f) Investigue, de forma exploratória, se funcionários com alta ou baixa produtividade também são os que:

- trabalham mais horas:

conclusão:

Sim. Funcionários com alta produtividade tendem a registrar uma média/mediana de horas trabalhadas maior , olhando o boxplot de Horas Trabalhadas, a caixa do grupo de Alta produtividade está deslocada significativamente para cima em relação ao de Baixa.

- possuem maior satisfação;

conclusão:

Não é um padrão. A satisfação média é muito parecida nos dois grupos, indicando que estar altamente satisfeito não garante maior produtividade (e vice-versa), olhe o boxplot de Satisfação. As caixas e as medianas dos dois grupos (Alta e Baixa) estão praticamente alinhadas na mesma altura.

- permanecem mais tempo na empresa;

conclusão:

Não há forte associação, o tempo de casa não parece ser um fator determinante para o funcionário produzir acima ou abaixo da mediana, as distribuições são sobrepostas e as medianas são muito próximas.

- realizam mais cursos;

Conclusão:

Sim, há uma leve associação. O grupo de alta produtividade costuma apresentar uma média ligeiramente maior de cursos concluídos,alguma diferença notável,no boxplot ou na tabela resumo de cursos, note se o grupo de Alta produtividade tem uma concentração maior em números elevados de cursos.

- atuam em determinados departamentos;

Conclusão:

Sim. Há indícios de que a produtividade varia dependendo do departamento em que o funcionário atua, um exemplo são: setores como TI e Vendas costumam apresentar uma proporção maior de funcionários no grupo de "Alta" produtividade se comparados ao RH.

- trabalham em regime de home-office.

conclusão:

Sim. Funcionários que trabalham home-office tem uma produtividade média consideravelmente maior do que funcionarios que não trabalham home-office, observa-se isso na tabela de frequência e no boxplot.

g) Descreva quais variáveis parecem apresentar associação mais forte com a produtividade (binária) e justifique sua conclusão com base nas evidências obtidas;

1. Horas Trabalhadas (Associação Muito Forte)

Evidência: Ao analisar o comportamento das horas, há uma disparidade enorme entre os dois grupos. O grupo classificado como Baixa produtividade trabalha, em média, cerca de 120 a 140 horas mensais, enquanto o grupo de Alta produtividade trabalha, em média, cerca de 180 a 200 horas. Os boxplots não se sobrepõem na parte central, mostrando que a quantidade de horas na jornada é o indicador que mais claramente separa um funcionário altamente produtivo de um de baixa produtividade.

2. Home-office (Associação muito forte)

Evidência: Olhando as tabelas de frequencia, os dados e as tabelas feitas no inicio da análise, notamos que há uma diferença extremamente acentuada entre os funcionários que trabalham remoto e os presenciais, os que trabalham remoto apresentam uma produtividade média maior que os que trabalham presencial, quando eu separei os dois grupos isso ficou ainda mais destacado

3. Cursos Realizados (Associação Forte)

Evidência: Há uma diferença clara na média e na mediana de capacitações. Os funcionários do grupo de Alta produtividade possuem uma concentração visivelmente maior de cursos realizados (com médias frequentemente acima de 3 ou 4 cursos), enquanto o grupo de Baixa produtividade se concentra em faixas menores (0 a 2 cursos). Isso destaca que o treinamento técnico está diretamente associado ao desempenho na entrega.

4. Departamento (Associação Moderada)

Evidência/Justificativa: A tabela de contingência (% cruzada) mostra que a produtividade não se distribui de forma igual (50% a 50%) entre as áreas. Setores mais técnicos ou finalísticos, como TI e Vendas, têm uma proporção muito maior de seus funcionários dentro do grupo de "Alta" produtividade (chegando a passar de 60% em alguns cenários). Em contrapartida, setores de suporte como o RH retêm uma proporção maior de funcionários na faixa "Baixa".

h) Discuta possíveis limitações dessa análise exploratória, destacando por que associações observadas não necessariamente possuem significância estatística. Indique quais seriam as análises complementares para a análise confirmatória e quais seriam as suas implicações

A análise exploratória de dados (AED) é uma etapa fundamental, mas possui limitações cruciais que impedem a tomada de decisões definitivas:

Efeito do Acaso (Flutuação Amostral): Os padrões e diferenças visuais que observamos nos gráficos deste conjunto de funcionários podem ser apenas uma coincidência da amostra coletada. Sem testes matemáticos, não podemos garantir que esses mesmos padrões se repetiriam se analisássemos toda a empresa ou novos contratados.

Correlação não implica Causalidade: O fato de haver uma forte associação entre duas variáveis não prova que uma é a causa direta da outra. É possível, por exemplo, que funcionários que já são naturalmente mais produtivos acabem assumindo mais demandas e fiquem mais tempo na empresa, invertendo a lógica da causa.

Fatores de Confusão : Uma associação que parece forte visualmente pode ser explicada por uma terceira variável que não foi isolada. Por exemplo, o departamento de TI pode parecer mais produtivo apenas porque os funcionários de lá realizam mais cursos, e não pelo departamento em si.

Para migrar de uma análise descritiva ("o que os dados mostram") para uma análise confirmatória ("o que a matemática

prova"), é necessário aplicar a Estatística Inferencial (fazer uma análise confirmatória).